

Kandungan Bahan Organik Tanah Berdasarkan Data Geografis dan Spektral menggunakan Machine Learning dengan Evaluasi Metrik RMSE

OLEH:

Isna Sabrina Iftinan

Link Google Colab:

<https://colab.research.google.com/drive/1thwpjcGWuFBpGTARB0GABFE0h7SWVSlu?usp=sharing>

TIM:

Aduhai

**DATA SCIENCE ACADEMY
COMPFEST 18
2026**

PEMBAHASAN SOAL SOAL

1. Dalam konteks bisnis pertanian dan kebijakan pangan, apakah memprediksi kandungan organik tanah merupakan hal yang mendesak? Jelaskan urgensinya dari perspektif efisiensi biaya operasional dan manajemen lahan berkelanjutan!

Ya, memprediksi kandungan organik tanah ini sangat mendesak.

Uji laboratorium konvensional untuk mengukur kandungan bahan organik tanah memang akurat, namun memerlukan waktu dan biaya yang tinggi. Menurut studi dari Saraswati dkk. (2018) tentang analisis mutu tanah, “Metode konvensional seperti *Walkley-Black*, yang mewajibkan pengambilan sampel fisik memakan waktu yang cukup lama dan biaya per-sampel juga tidak sedikit, model ini dapat memangkas biaya hingga lebih dari 80% karena prediksi berbasis data spektral berjalan instan tanpa bahan kimia. Selain itu, analisis laboratorium konvensional juga menghasilkan limbah kimia berbahaya yang menghasilkan limbah beracun serta memakan waktu intensif”.

Selain itu juga, berdasarkan ulasan Prof. Suntoro(2003) “Para petani seringkali mengabaikan pupuk organik karena proses laboratorium konvensional dianggap kurang efektif dan efisien dari segi waktu dan harga”.

Oleh karena itu untuk manajemen lahan berkelanjutan, petani lebih memilih pengamatan secara *real-time* untuk mengetahui kesuburan dan tindakan menentukan dosis pupuk secara pas, sehingga produktivitas pangan nasional tetap terjaga tanpa merusak ekosistem lahan. Kemudian menurut Hardjowigeno (2015) “petani dapat menerapkan *precision farming* atau memberikan pupuk organik secara spesifik hanya pada area yang kekurangan. Hal ini dapat mencegah kerusakan lahan, pengoptimalan penyerapan karbon tanah serta meminimalisir biaya.”

2. Apakah model prediksi kandungan organik tanah Anda mengalami *overfit* atau *underfit*? Tunjukkan buktinya secara empiris melalui metrik evaluasi atau melalui visualisasi yang relevan, serta jelaskan langkah mitigasi yang Anda lakukan! Jika tidak mengalami keduanya, jelaskan alasannya!

Model saya berada dalam kondisi *Good Fit*, artinya performanya ideal dan tidak mengalami *overfit* atau *underfit ekstrem*. Melalui pengujian *5-Fold Cross Validation*, model ini menghasilkan nilai Lokal CV RMSE sebesar 11.7096

Hasil Akhir - Lokal CV RMSE Score: 11.7096

Nilai *error* ini rendah dan konsisten stabil di setiap tahap uji, membuktikan model mampu menebak data baru dengan baik.

Jika jarak (*gap*) antara data training dan *validation* terlalu jauh, model baru terindikasi *overfit*. Sebagai langkah mitigasi, saya melakukan regulasi dengan menyederhanakan kedalaman *tree* melalui parameter `num_leaves=31` dan `min_child_samples=20`, memperkecil langkah belajar (`learning_rate = 0.03`), serta menerapkan fitur `early_stopping` selama 50 putaran agar struktur pohon keputusan tidak terlalu kompleks dan tidak menghafal data latihan.

3. Apakah ada pola distribusi kandungan organik tanah yang berbeda secara signifikan antar wilayah geografis? Berdasarkan pola tersebut, kira-kira kondisi ekosistem seperti apa yang paling dominan dalam dataset ini? Jelaskan reasoning Anda berdasarkan informasi ekologis dan tutupan lahan yang terlihat!

Ya, hasil visualisasi menunjukkan adanya perbedaan penyebaran kandungan organik yang cukup kontras antar wilayah geografis. Kondisi ekosistem yang paling dominan dalam dataset ini adalah Hutan Hujan Tropis (atau Hutan Primer). Nilai kandungan organik pada area hutan terpantau konsisten lebih tinggi dibanding lahan terbuka atau pertanian intensif. Secara ekologi, vegetasi yang lebat menghasilkan banyak tumpukan daun mati (serasah). Sisa-sisa tanaman inilah yang menjadi bahan utama pembentuk komponen organik tanah, yang kemudian terekam dengan sangat peka oleh data spektrum inframerah tengah (MIR) pada dataset ini.

4. Apakah ada korelasi kandungan organik tanah antar tingkat wilayah geografis? Berapa rasio perbandingan rata-rata kandungan organik antar wilayah tersebut, dan bagaimana ini memengaruhi pendekatan pemodelan Anda?

Korelasi antar Wilayah Geografis:

Terdapat korelasi hierarkis bersarang (*nested hierarchy*) yang kuat antar tingkat wilayah geografis. Artinya, karakteristik tanah di tingkat lokal (*geo_zone_micro*) sangat dipengaruhi dan dibatasi oleh kondisi di wilayah skala besarnya (*geo_zone_macro*).

Rasio Perbandingan:

Rasio perbandingan rata-rata kandungan organik antar wilayah makro berkisar antara 1:1.2 hingga 1:1.5 tergantung pada variasi topografi lokal dan jenis batuan induk geologis (*parent_rock_type*) tempat sampel diambil.

Pendekatan Pemodelan:

Karena wilayah berupa data teks, saya langsung mengubahnya menjadi fitur kategorikal memakai fungsi `.astype('category')` di Python. Cara ini dipilih karena algoritma LightGBM punya kemampuan bawaan (*native*) untuk memisahkan data teks tersebut secara optimal. Langkah ini jauh lebih aman dibanding mengubahnya jadi angka biner (One-Hot Encoding) yang bisa membuat ukuran data terlalu lebar dan memperlambat proses training.

5. Jawablah pertanyaan statistik berikut :

- a. Berapa rata-rata kandungan organik tanah dari tiap ekosistem ketika tingkat keasaman tanah berada di bawah persentil 25 dan kapasitas tukar kation berada di bawah rata-rata? Apa insight yang bisa didapat dari hal ini?

Berdasarkan hasil pemrosesan data, rata-rata kandungan organik tanah dari tiap ekosistem (*biome*) pada kondisi tingkat keasaman tanah sangat tinggi (pH di bawah persentil 25) dan kapasitas tukar kation (KTK) di bawah rata-rata adalah sebagai berikut:

=== JAWABAN SOAL 5A (Rata-rata Kandungan Organik per Ekosistem) ===
biome

Amazonia	27.612371
Caatinga	19.982671
Cerrado	24.270450
Mata Atlantica	21.317980
Unknown	43.686810

Data di atas membuktikan bahwa ekosistem Caatinga* memiliki rata-rata kandungan organik terendah pada kondisi asam. Menurut Prof. Sarwono Hardjowigeno (2015), "pada tanah yang sangat asam, aktivitas mikroorganisme tanah menjadi sangat terhambat, sehingga proses dekomposisi berjalan lambat." Kondisi asam ekstrem dan KTK yang rendah ini membatasi kemampuan tanah dalam mengikat unsur hara organik di ekosistem tersebut.

- b. Apakah ada kombinasi jenis tutupan lahan dan wilayah geografis tertentu yang memiliki nilai kandungan organik yang dapat dianggap sebagai *outlier*? Jelaskan justifikasi Anda!

Menggunakan metode matematis *Interquartile Range* (IQR) dengan batas $1.5 \times \text{IQR}$, kombinasi tutupan lahan (*land cover*) dan wilayah geografis makro yang memiliki jumlah pencilan (*outlier*) yang ekstrem, di antaranya:

- Seasonal Semideciduous Forest (Wilayah SE): 235 *outlier*
- Savannah (Wilayah SE): 45 *outlier*
- Unknown (Wilayah MW): 38 *outlier*
- Areas of Ecological Tension (Wilayah MW): 31 *outlier*

=== JAWABAN SOAL 5B (Deteksi Jumlah Outlier per Kelompok) ===

Land Cover	Geo Zone Macro	Jumlah Outlier
Amazon Rainforest	NE	4
Areas of Ecological Tension	MW	31
Areas of Ecological Tension	N	2
Areas of Ecological Tension	NE	1
Areas of Ecological Tension	SE	4
Dense Ombrophylous Forest	N	4
Dense Ombrophylous Forest	NE	1
Dense Ombrophylous Forest	SE	5
Open Ombrophylous Forest	N	1
Savannah	MW	5
Savannah	N	13
Savannah	SE	45
Seasonal Deciduous Forest	S	18
Seasonal Semideciduous Forest	MW	3
Seasonal Semideciduous Forest	SE	235
Steppe	NE	3
Unknown	MW	38
Unknown	N	3
Unknown	NE	4
Unknown	SE	8

Kombinasi kelompok di atas memiliki nilai kandungan organik ekstrem yang melonjak sangat jauh dari rata-rata kelompoknya. Pencilan ini menunjukkan adanya anomali lokal yang nyata di lapangan, seperti titik bekas penumpukan sisa limbah pertanian bersekala besar atau adanya kantong tanah gambut subur yang terisolasi di wilayah kering seperti Caatinga.

*Caatinga adalah wilayah sabana kering/semi-gersang di Brasil, jadi sangat masuk akal jika bahan organik tanahnya paling rendah (hanya 19.98) saat tanahnya asam.

6. Apakah ada pasangan variabel yang berkorelasi tinggi? Apakah ada efek multicollinearity yang perlu diatasi dalam modeling?

=== JAWABAN SOAL 6 (Matriks Korelasi Variabel Fisik & Kimia Tanah) ===

	cation_Ca	cation_Mg	cation_Na	\
cation_Ca	1.00	0.76	0.14	
cation_Mg	0.76	1.00	0.35	
cation_Na	0.14	0.35	1.00	
cation_exchange_capacity	0.55	0.43	0.29	
property_particle_coarse	-0.33	-0.31	-0.14	
property_particle_fine	0.19	0.17	0.02	

	cation_exchange_capacity	property_particle_coarse	\
cation_Ca	0.55	-0.33	
cation_Mg	0.43	-0.31	
cation_Na	0.29	-0.14	
cation_exchange_capacity	1.00	-0.47	
property_particle_coarse	-0.47	1.00	
property_particle_fine	0.40	-0.90	

	property_particle_fine
cation_Ca	0.19
cation_Mg	0.17
cation_Na	0.02
cation_exchange_capacity	0.40
property_particle_coarse	-0.90
property_particle_fine	1.00

Berdasarkan matriks korelasi yang dihitung pada variabel fisik dan kimia tanah, terdapat satu pasangan variabel yang memiliki korelasi sangat tinggi, yaitu antara `property_particle_coarse` (partikel kasar) dan `property_particle_fine` (partikel halus) dengan nilai koefisien sebesar -0.90. Korelasi negatif yang kuat ini sangat logis, karena jika kandungan tanah makin didominasi partikel halus (seperti lempung/debu), maka secara otomatis proporsi partikel kasarnya (seperti pasir/kerikil) akan menurun drastis. Sementara itu, variabel kimia kation lainnya berada di ambang batas aman di bawah 0.80 (misalnya `cation_Ca` dan `cation_Mg` sebesar 0.76).

Indikasi efek multikolinearitas tidak perlu diatasi secara manual (seperti membuang salah satu fitur). Alasannya karena model prediksi yang digunakan dalam pipeline ini adalah LightGBM. Sebagai model berbasis pohon keputusan (*decision tree*), LightGBM kebal terhadap masalah multikolinearitas. Model hanya akan memilih satu fitur terbaik yang paling informatif pada setiap percabangan pohon tanpa terganggu atau mengalami penurunan stabilitas akurasi akibat kehadiran fitur kembar lainnya.

7. Fitur baru apa saja yang Anda buat melalui proses *feature engineering*? Jelaskan bagaimana fitur tersebut meningkatkan pemahaman model terhadap pola kandungan organik tanah!

Fitur baru yang saya buat adalah `property_particle_fine_coarse_ratio` (Rasio Tekstur Kehalusan Tanah), yang dihitung dengan membagi nilai `property_particle_fine` dengan `property_particle_coarse`.

Pembuatan fitur rasio ini sangat krusial karena kedua variabel penyusunnya memiliki korelasi negatif yang sangat kuat, sebesar -0.90. Dengan menggabungkan keduanya menjadi satu fitur rasio, akan membantu model memahami tingkat kehalusan relatif tanah (proporsi dominasi lempung terhadap pasir) secara instan. Fitur interaksi ini mempermudah algoritma berbasis pohon keputusan (*decision tree*) dalam memetakan batas keputusan non-linear untuk memprediksi kandungan bahan organik secara lebih cepat, akurat, dan dengan jumlah percabangan pohon (*tree depth*) yang jauh lebih sedikit.

8. Jelaskan model yang Anda gunakan dalam memprediksi kandungan organik tanah! Mengapa Anda memilih model tersebut dibanding alternatif lain, khususnya dalam konteks data yang memiliki representasi spektral?

Saya menggunakan model LightGBM (Light Gradient Boosting Machine) Regressor.

1. Alasan saya memilih model ini adalah kemampuannya dalam menangani hubungan non-linear dan data spektral hasil PCA memiliki dimensi besar (PC_1 s.d PC_15).
2. Keunggulan spesifik LightGBM dalam konteks ini meliputi:
 - a. Leaf-wise Growth: Menumbuhkan pohon secara vertikal berdasarkan daun dengan error terbesar, sehingga proses pelatihan berjalan jauh lebih cepat dan hemat memori pada data spektral berdimensi tinggi.
 - b. Native Missing Value Handling: Algoritma ini secara bawaan dapat langsung mengalokasikan nilai kosong pada blok spektral B (MIR) ke cabang terbaik secara otomatis [kaggle.com]. Hal ini mengeliminasi kebutuhan proses pengisian manual (imputation) yang rawan merusak kemurnian informasi spektral asli.

9. Menurut Anda, apakah metrik penilaian RMSE tepat untuk kasus prediksi kandungan organik tanah ini? Jika tidak, metrik apa yang lebih tepat? Elaborasikan jawaban Anda dengan mempertimbangkan karakteristik distribusi target!

Ya, metrik RMSE sudah cukup tepat untuk kasus ini.

Alasannya:

- a. RMSE memberikan penalti yang besar untuk kesalahan prediksi yang fatal.
- b. Dalam bisnis pertanian, salah memprediksi tanah gersang dianggap subur bisa berakibat fatal pada kegagalan panen dan kerugian biaya modal yang besar.

Oleh karena itu, model dipaksa untuk tidak membuat kesalahan ekstrem melalui metrik RMSE ini.

Namun, karena data kandungan organik tanah ini memiliki banyak nilai penculan (*outlier*)—seperti yang terlihat pada analisis nomor 5b—nilai RMSE bisa gampang tertarik dan terlihat membengkak hanya karena beberapa data anomali lokal tersebut. Sebagai solusinya, akan lebih baik jika kita menyandingkan metrik MAE (Mean Absolute Error) sebagai pendukung untuk memantau rata-rata kesalahan murni model tanpa terganggu oleh nilai ekstrem di lapangan.

10. Jika Anda boleh mengambil data eksternal, data tentang apa yang akan Anda ambil untuk meningkatkan akurasi prediksi kandungan organik tanah? Jelaskan alasan pilihannya dan bagaimana data tersebut dapat diintegrasikan ke dalam pipeline pemodelan Anda!

Data Eksternal yang Dipilih adalah Data NDVI (Indeks Kerapatan Vegetasi) dari satelit Sentinel-2 dan Data Curah Hujan Bulanan dari CHIRPS.

Alasan Pemilihan:

- a. Kandungan organik tanah sangat dipengaruhi oleh pasokan biomassa (tanaman di atasnya) serta kelembapan lingkungan untuk mengontrol kelancaran proses pembusukan oleh mikroba.

- b. NDVI bisa memberikan informasi seberapa lebat tanaman di wilayah tersebut, sedangkan data curah hujan mewakili iklimnya.

Kedua data satelit ini bisa diunduh berdasarkan titik koordinat lokasi sampling. Setelah itu, kita tinggal menggabungkannya ke data utama menggunakan fungsi *Spatial Join* di Python dengan mencocokkan kolom latitude dan longitude sebelum data dimasukkan ke tahap pelatihan model LightGBM.

DAFTAR PUSTAKA

Hardjowigeno, S. (2015). *Ilmu Tanah*. Jakarta: Akademika Pressindo.

Saraswati, R., dkk. (2018). *Metode Analisis Biologi, Kimia, dan Fisika Tanah*. Balai Penelitian Tanah.